

Practical Descriptive Statistics

PTP Program



Training Guidelines

Persyaratan dan Ekspektasi untuk Peserta Pelatihan:


1. **Prerequisite:** Peserta diharapkan sudah memiliki pengetahuan dasar tentang python dan Pandas.
2. **Active Participation:** Peserta harus terlibat aktif dengan materi pelatihan, mencatat poin-poin penting dan penjelasan yang diberikan oleh instruktur.
3. **Clear Instruction:** Instruktur bertanggung jawab untuk menyampaikan materi pelatihan dengan cara yang jelas dan ringkas, memastikan semua peserta memahami topik yang dibahas.
4. **Hands-on Practice:** Sebagian besar pelatihan akan melibatkan latihan praktis yang dilakukan menggunakan **Google Colab (Jupyter Notebook)**. Anda dapat mengakses Google Colab yang tersedia di slide terakhir.

List Of Contents

- Pengenalan Statistika Deskriptif
- Jenis Data dalam Statistika
- Basic Probability
- Central Tendency
- Jenis Distribusi Data
- Outlier
- Analisa Korelasi

Pengenalan statistika

Statistika Dalam Dunia Data



- Statistik sangat penting dalam *Data Science*, karena merupakan inti dari DS yang membantu kita untuk memahami dan menganalisis data.
- Statistika adalah cabang ilmu yang mempelajari pengumpulan, pengolahan, analisis, interpretasi, dan penyajian data. Tujuan utamanya adalah untuk mendapatkan informasi yang bermakna dan dapat membawa kita pada **pengambilan keputusan yang lebih baik** berdasarkan data sebelum kita menggunakan model machine learning dan algoritma canggih lainnya.
- Salah satu penggunaan metode statistik adalah kita dapat dengan mudah menarik kesimpulan umum, namun hanya berdasarkan data sampel.

Pengenalan statistika


Definisi Statistika Deskriptif

- Statistik deskriptif adalah cabang statistik yang berfokus pada meringkas dan mendeskripsikan karakteristik utama dari suatu dataset. Ini melibatkan penggunaan berbagai ukuran dan teknik statistik untuk memberikan ringkasan yang singkat dan bermakna dari data.
- Statistik deskriptif bertujuan untuk memberikan informasi tentang kecenderungan sentral, variabilitas, dan distribusi data.

Pengenalan statistika

Jenis Data dalam Statistika

Sebelum kita membahas lebih lanjut tentang metode statistik, kita perlu memahami jenis data apa yang dapat ditangani. Hal ini penting untuk dipahami karena metode yang digunakan bergantung pada jenis data tersebut



Pengenalan statistika

Basic Probability

Statistika berkaitan dengan probabilitas. **Probabilitas** adalah angka yang menggambarkan peluang atau kemungkinan terjadinya suatu peristiwa tertentu. Probabilitas dapat diekspresikan dalam bentuk proporsi yang berkisar antara 0 hingga 1, dan juga dapat diekspresikan dalam bentuk persentase yang berkisar antara 0% hingga 100%.




Berapa peluang terjadinya hujan sekitar pukul 12:00 siang? Selama 6 hari, hanya pada tanggal 6 Juni yang terjadi hujan pada pukul 12.00 siang. Jadi, peluang hujan pada pukul 12 siang hanya $\frac{1}{6}$ atau 16,67%.

Basic Probability

Probability Distribution

Probability distribution adalah fungsi statistik yang menggambarkan kemungkinan nilai dan kemungkinan yang dapat diambil oleh variabel acak dalam rentang tertentu. Dengan kata lain, probability distribution memberi tahu kita seberapa besar kemungkinan setiap nilai yang mungkin dari variabel acak akan terjadi.




Contoh Histogram & Probability Distribution Function (PDF) untuk Tinggi Badan

Basic Probability

Probability Distribution

Distribusi probabilitas memiliki banyak jenis dan dapat digunakan sesuai dengan masalah yang Anda tangani. Distribusi probabilitas yang menghitung frekuensi daripada probabilitas, dapat kita sebut sebagai distribusi data. Berikut ini adalah ikhtisar jenis-jenis distribusi probabilitas:



Measurement of Central Tendency

Mean, Median, Modus

- **Mean:** Rata-rata dihitung dengan menjumlahkan semua nilai dalam kumpulan data dan membaginya dengan jumlah total nilai. Rata-rata dipengaruhi oleh nilai ekstrim dan memberikan ukuran rata-rata aritmatika data. Rata-rata digunakan secara luas dan berlaku untuk kumpulan data dengan distribusi simetris.
- **Median:** Median adalah nilai tengah dalam kumpulan data yang diurutkan. Median memisahkan bagian atas dari bagian bawah data. Jika ada jumlah pengamatan genap, median adalah rata-rata dari dua nilai tengah. Median tidak dipengaruhi oleh nilai ekstrim dan cocok untuk kumpulan data dengan distribusi miring atau outlier.
- **Mode:** Modus mewakili nilai yang paling sering muncul dalam kumpulan data. Modus dapat berupa nilai tunggal atau beberapa nilai jika ada seri. Modus berguna untuk data kategorikal atau diskrit, dan juga dapat diterapkan pada data kontinu dengan mengelompokkan nilai ke dalam interval.

Setiap ukuran kecenderungan sentral memiliki kelebihan dan keterbatasannya sendiri, dan pilihan yang mana yang akan digunakan bergantung pada sifat data dan tujuan analisis. Rata-rata memberikan rata-rata yang tepat tetapi dapat dipengaruhi oleh outlier. Median kuat terhadap outlier tetapi mungkin tidak sepenuhnya menangkap karakteristik distribusi. Modus berguna untuk mengidentifikasi nilai yang paling umum tetapi mungkin tidak ada atau unik dalam beberapa set data.

Measurement of Dispersion

Bagaimana Kita Mengetahui Penyebaran Data?


Untuk menentukan penyebaran atau variabilitas data, kita dapat memanfaatkan berbagai ukuran statistik. Berikut ini adalah beberapa metode umum:

- **Range:** Rentang menyediakan cara sederhana untuk menilai penyebaran data. Rentang dihitung dengan mengurangi nilai terkecil dari nilai terbesar dalam kumpulan data. Namun, rentang hanya mempertimbangkan nilai ekstrim dan mungkin tidak menangkap gambaran variabilitas secara keseluruhan.
- **Interquartile Range (IQR):** IQR mengukur penyebaran bagian tengah data. Ini adalah perbedaan antara kuartil ketiga (persentil ke-75) dan kuartil pertama (persentil ke-25) dari kumpulan data. Dengan berfokus pada 50% tengah data, IQR kurang sensitif terhadap nilai ekstrim.
- **Variance:** Varians menghitung deviasi kuadrat rata-rata setiap titik data dari mean. Ini memberikan ukuran penyebaran data secara keseluruhan, dengan mempertimbangkan semua nilai. Namun, varians dalam satuan kuadrat, sehingga lebih sulit untuk ditafsirkan secara langsung.
- **Standard Deviation:** Deviasi standar adalah akar kuadrat dari varians. Ini merupakan jumlah rata-rata atau tipikal penyimpangan titik data dari nilai rata-rata. Ini merupakan ukuran penyebaran yang banyak digunakan karena menggunakan satuan yang sama dengan data asli, sehingga lebih mudah ditafsirkan.

Measurement of Dispersion


Box and Whisker Plot

Box and Whisker Plot, yang umumnya dikenal sebagai Box Plot, adalah representasi grafis dari distribusi kumpulan data. Plot ini memberikan ringkasan penyebaran data, pusat, dan setiap outlier. Plot ini terdiri dari lima komponen utama: nilai minimum, kuartil pertama (Q1), median (Q2), kuartil ketiga (Q3), dan nilai maksimum.




Distribution


Discrete Distribution



Uniform distribution mengacu pada distribusi statistik di mana semua hasil memiliki kemungkinan yang sama. Kelemahan dari distribusi ini adalah sering kali tidak memberikan informasi yang relevan. Karena semua nilai memiliki kemungkinan yang sama, distribusi ini tidak memberikan kita kekuatan prediksi yang nyata.




Bernoulli distribution merupakan salah satu distribusi yang paling mudah dipahami. Setiap kejadian dengan satu kali percobaan dan hanya dua hasil mengikuti distribusi Bernoulli. Melempar koin atau memilih antara Benar dan Salah dalam sebuah kuis merupakan contoh distribusi Bernoulli.




Poisson distribution membahas tentang frekuensi terjadinya suatu peristiwa dalam interval tertentu. Alih-alih probabilitas suatu peristiwa, distribusi Poisson mengharuskan mengetahui seberapa sering peristiwa itu terjadi dalam periode atau jarak tertentu.

Distribution


Continuous Distribution



Distribusi normal adalah distribusi yang paling sering digunakan dalam ilmu data. Dalam grafik distribusi normal, data terdistribusi secara simetris tanpa adanya skew. Distribusi normal sering muncul dalam alam dan kehidupan dalam berbagai bentuk. Ada varian lain dari distribusi ini yang disebut distribusi **t-Student**.



Distribusi eksponensial digunakan untuk memodelkan waktu yang dibutuhkan antara terjadinya peristiwa-peristiwa yang berbeda. Misalnya, dalam keuangan, distribusi ini digunakan untuk mengukur kemungkinan terjadinya **default** (gagal bayar) berikutnya pada portofolio aset keuangan.




Chi-squared distribution umumnya digunakan dalam **pengujian hipotesis** dan menganalisis data kategorikal. Distribusi ini memainkan peran penting dalam **inferensi statistik** dan membantu peneliti untuk menarik kesimpulan tentang parameter populasi berdasarkan data yang diamati.

Distribution

Normality Test - Skewness

Banyak metode statistik yang menggunakan asumsi distribusi normal. Lalu, bagaimana kita bisa tahu apakah data kita berdistribusi normal? Kita dapat melakukan **uji normalitas** pada data kita dengan menggunakan metrik **skewness** dan **kurtosis**. **Skewness** adalah ukuran yang menggambarkan **simetri** dari distribusi data.



Skewness mengukur sejauh mana data terdistribusi secara tidak merata, atau apakah data condong ke sisi kiri (negatif) atau sisi kanan (positif) dari distribusi normal.


- **Skewness < -1** atau **Skewness > 1**: Distribusi dikatakan **sangat miring**.
- **-1 < Skewness < -0.5** atau **0.5 < Skewness < 1**: Distribusi dikatakan **cukup miring**.
- **-0.5 < Skewness < 0.5**: Distribusi dikatakan **mendekati simetris**

<Normal Distribution>

Distributions

Normality Test - Kurtosis

Kurtosis mengukur bentuk ekor distribusi dan adanya **outlier** (data yang sangat jauh dari nilai lainnya). Kurtosis menggambarkan **berat** atau **ringannya** ekor distribusi dibandingkan dengan ekor distribusi normal.



- **Leptokurtic:** Distribusi **Leptokurtic** memiliki **ekor yang lebih berat** dan **puncak yang lebih tinggi** dibandingkan distribusi normal. Ini menunjukkan bahwa data memiliki lebih banyak **outlier** atau nilai ekstrim (nilai yang sangat jauh dari rata-rata) dibandingkan dengan distribusi normal.
- **Mesokurtic:** Distribusi **Mesokurtic** memiliki **ekor dan puncak yang serupa** dengan distribusi normal. Data mengikuti **bentuk distribusi normal**, yang berarti data tersebar di sekitar rata-rata dengan cara yang konsisten tanpa adanya ekor yang terlalu berat atau ringan.
- **Platykurtic:** Distribusi **Platykurtic** memiliki **ekor yang lebih ringan** dan **puncak yang lebih datar** dibandingkan distribusi normal. Ini menunjukkan bahwa data **lebih tersebar** secara merata dan memiliki lebih sedikit **outlier** atau nilai ekstrim dibandingkan dengan distribusi normal.

Outliers and Extreme Value Analysis

Apa itu Outliers?

Outlier adalah **titik data** yang berbeda secara signifikan dari pengamatan lainnya dalam suatu kumpulan data. **Outlier** merujuk pada nilai-nilai yang sangat **tinggi** atau **rendah** dibandingkan dengan sebagian besar data dalam kumpulan tersebut.


Memahami dan mengidentifikasi **outlier** (nilai yang sangat berbeda dari sebagian besar data) sangat penting untuk beberapa alasan berikut:

- Outlier Dapat Menunjukkan Kesalahan atau Anomali dalam Proses Pengumpulan atau Pencatatan Data
- Outlier Dapat Memberikan Dampak Substansial pada Ukuran Statistik Seperti Rata-Rata dan Simpangan Baku
- Banyak Model Statistik Mengasumsikan Data Berdistribusi Normal atau Mengikuti Distribusi Tertentu
- Outlier Dapat Memberikan Pengaruh Tidak Proporsional pada Hasil Analisis Statistik
- Dalam beberapa kasus, outlier Dapat Mewakili Kasus Unik atau Krusial yang Memerlukan Perhatian atau Penyidikan Khusus
- Outlier Dapat Mempengaruhi Interpretasi Data dan Proses Pengambilan Keputusan:

Outliers and Extreme Value Analysis

How to Detect


Ada dua teknik populer untuk mendeteksi outlier dalam data kita berdasarkan distribusi data.



Digunakan untuk distribusi normal (skewness < $|\pm 0.5|$)

Upper boundary: $mean + 3 \cdot std$

Lower boundary: $mean - 3 \cdot std$



Digunakan untuk distribusi miring (skewness > $|\pm 0.5|$)

Upper boundary: $Q3 + 1.5 \cdot IQR$


Lower boundary: $Q1 - 1.5 \cdot IQR$

$IQR = Q3 - Q1$

Pengenalan Korelasi

Correlation Analysis

Korelasi adalah ukuran statistik yang mengukur hubungan atau asosiasi antara dua variabel. Ukuran ini menentukan sejauh mana perubahan dalam satu variabel terkait dengan perubahan dalam variabel lain. Korelasi sering dinyatakan sebagai koefisien korelasi, yang menunjukkan kekuatan dan arah hubungan.



Koefisien korelasi berkisar antara -1 hingga +1. Koefisien korelasi sebesar +1 menunjukkan korelasi positif sempurna, yang berarti bahwa saat satu variabel meningkat, variabel lainnya juga meningkat secara proporsional. Koefisien korelasi sebesar -1 menunjukkan korelasi negatif sempurna, yang berarti bahwa saat satu variabel meningkat, variabel lainnya menurun secara proporsional. Koefisien korelasi sebesar 0 menunjukkan tidak ada hubungan linier antara kedua variabel.

Pengenalan Korelasi

Correlation Analysis

Terdapat tiga teknik korelasi yang umum digunakan, yaitu **Pearson**, **Spearman**, dan **Kendall**.

- **Pearson**: Dikenal dengan simbol **r**, mengukur hubungan linier antara dua variabel kontinu. Pearson mengasumsikan bahwa data mengikuti distribusi normal. Pearson sangat sensitif terhadap **outlier** dan mengasumsikan adanya hubungan linier, sehingga cocok digunakan untuk menilai hubungan linier antara variabel kontinu yang berdistribusi normal.
- **Spearman**: Dikenal dengan simbol **ρ (rho)**, mengukur hubungan **monotonik** antara variabel. Spearman tidak mengasumsikan distribusi tertentu pada data dan lebih cocok untuk variabel yang mungkin tidak memiliki hubungan linier. Spearman lebih tahan terhadap **outlier** dibandingkan dengan korelasi Pearson dan dapat menangkap hubungan non-linier. Korelasi Spearman sering digunakan ketika variabel memiliki distribusi yang miring atau ketika hubungan antar variabel lebih baik dijelaskan oleh urutan atau peringkat data.
- **Kendall**: Dikenal dengan simbol **τ (tau)**, juga mengukur kekuatan hubungan **monotonik** antara variabel. Seperti korelasi Spearman, Kendall tidak mengasumsikan distribusi tertentu pada data. Kendall juga tahan terhadap **outlier** dan dapat menangani hubungan non-linier. Korelasi Kendall umumnya digunakan ketika berhadapan dengan variabel **kategori** atau **ordinal**.



External References

- Google Colab -
Statistika Deskriptif

[Visit Here](#)