

Introduction to Machine Learning & Regression

PTP Program





Syarat dan Aturan dalam Pelatihan

Untuk mengikuti materi pelatihan berikut ada beberapa hal yang harus diperhatikan oleh peserta:

- Peserta diharapkan sudah memiliki pengetahuan dasar tentang Data Analysis dan Python.
- Peserta diharapkan memperhatikan materi dan mencatat materi atau penjelasan yang disampaikan dari instruktur.
- Instruktur diharapkan dapat menjelaskan materi dengan jelas dan memastikan peserta pelatihan dapat memahami topik yang dibahas.
- Materi yang diajarkan sebagian besar adalah praktik atau menggunakan Google Colab (Jupyter Notebook).



Daftar Isi

- Pengenalan Machine Learning
- Jenis Machine Learning
- Machine Learning Workflow
- Linear Regression



Objectives

- Peserta dapat menjelaskan apa itu machine learning, perbedaan antara AI, machine learning, dan deep learning, serta aplikasi umum machine learning dalam berbagai bidang.
- Peserta dapat mengidentifikasi dan memahami perbedaan antara supervised learning, unsupervised learning, dan reinforcement learning, serta contoh penerapan masing-masing.
- Peserta dapat memahami langkah-langkah utama dalam workflow machine learning, termasuk pengumpulan data, preprocessing data, pemilihan model, pelatihan model, evaluasi, dan implementasi.
- Peserta dapat memahami cara membuat pemodelan Linear Regression.




Pengenalan Dasar Machine Learning

Machine Learning

Apa itu Machine Learning

Machine Learning adalah bidang studi yang memberikan kemampuan kepada komputer untuk belajar tanpa diprogram secara eksplisit. (Diperkenalkan oleh Arthur Samuel, 1959)

Dalam Machine learning, alih-alih memberitahu komputer langkah-langkah yang tepat, kita memberikan data dan membiarkan algoritma menemukan pola dan membuat keputusan sendiri.



Machine Learning

Terminologi

Tiga terminologi dasar dalam pembuatan **Model Machine Learning**:

- **Fitur (Feature)**
 - **Definisi:** Fitur adalah **variabel independen** atau **input** yang digunakan untuk memprediksi hasil. Fitur mewakili karakteristik atau properti dari data.
 - **Contoh Sederhana:**
 - Jika kita ingin memprediksi harga rumah, maka fitur-fiturnya bisa berupa ukuran rumah (m2), jumlah kamar tidur, jumlah kamar mandi dan Lokasi.
- **Target (Label)**
 - **Definisi:** Target adalah **variabel dependen** atau **output** yang ingin diprediksi oleh model.
 - **Contoh Sederhana:**
 - Untuk prediksi harga rumah, targetnya adalah **harga rumah**.
- **Model**
 - **Definisi:** **Model** adalah **representasi matematis atau algoritma** yang digunakan untuk menemukan pola dari data. Model bertugas untuk mempelajari pola dari data selama proses pelatihan (training) dan menggunakannya untuk membuat prediksi pada data.

Machine Learning

Tipe Machine Learning

Machine learning dibagi menjadi beberapa kategori yaitu:


- supervised learning
- unsupervised learning
- Semi Supervised Learning
- reinforcement learning

Machine Learning

Supervised Learning

Supervised learning adalah kategori machine learning yang menggunakan kumpulan data historis berlabel untuk melatih algoritma melakukan klasifikasi atau regresi.

Tujuan utama dari supervised learning adalah untuk mempelajari hubungan atau pola antara input dan output sehingga model dapat membuat prediksi akurat pada data baru yang belum pernah dilihat sebelumnya.



Machine Learning

Supervised Learning

Supervised Learning dibagi menjadi dua jenis, yaitu:

- **Classification** : Proses memprediksi atau mengklasifikasikan data ketika variabel output bersifat kategoris yaitu dengan 2 kelas atau lebih. Contohnya prediksi seseorang terkena Stroke atau Tidak terkena Stroke.
- **Regression**: Proses untuk memodelkan dan menganalisis hubungan antara satu atau lebih variabel independen (fitur) dengan variabel dependen (target) yang bersifat kontinu. Misalkan, prediksi harga rumah, gaji karyawan, dll.

Algoritma yang digunakan dalam supervised learning seperti linear regression, logistic regression, random forest, support vector machine (SVM), neural networks, naïve bayes dan banyak lagi.

Machine Learning

Classification

Klasifikasi dibagi menjadi 3 jenis: Binary Classification, Multiclass Classification dan Multilabel Classification.

Binary Classification adalah jenis klasifikasi di mana model memprediksi satu dari dua kelas/label berdasarkan data yang diberikan. Dengan kata lain, hanya ada dua kategori yang bisa dipilih oleh model.

Contoh:

- Spam Filtering: Memprediksi apakah sebuah SMS adalah spam atau bukan. Kelasnya adalah spam dan bukan spam.
- TBC Detection from a Patient: Memprediksi apakah seorang pasien terkena TBC atau tidak. Kelasnya adalah positif TBC dan negatif TBC.
- Telco Customer Churn: Memprediksi apakah seorang customer berpotensi Churn atau tidak.

Machine Learning

Classification

Multiclass Classification adalah jenis klasifikasi di mana model memprediksi satu dari beberapa kelas/label berdasarkan data yang diberikan. Dalam hal ini, lebih dari dua kategori tersedia, dan model harus memilih satu dari banyak kategori yang mungkin.

Contoh:

- Animal Detection from an Image: Memprediksi jenis hewan apa yang ada dalam sebuah gambar, misalnya anjing, kucing, atau burung. Ada lebih dari dua kelas yang mungkin.
- Face Recognition: Memprediksi siapa seseorang berdasarkan wajahnya. Kelasnya bisa berupa beberapa individu yang berbeda, seperti John, Jane, Paul, dll.

Machine Learning

Classification

Multilabel Classification adalah jenis klasifikasi di mana model memprediksi satu atau lebih kelas/label untuk setiap data yang diberikan. Dalam masalah multilabel, setiap instance dapat memiliki beberapa label sekaligus dari sekumpulan kategori yang tersedia, sehingga target kelas bisa lebih dari satu.

Berbeda dengan multiclass classification, di mana hanya satu kategori yang dipilih, dalam multilabel classification, model dapat memilih lebih dari satu label yang relevan untuk setiap instance.

Contoh:

- News Classification: Memprediksi kategori atau topik dari sebuah artikel berita. Sebuah berita dapat masuk ke lebih dari satu kategori, seperti:
 - (politik, ekonomi): Artikel tersebut bisa membahas topik politik dan ekonomi sekaligus.
 - (teknologi, hiburan): Berita ini bisa tentang perkembangan teknologi dalam industri hiburan.

Machine Learning

Classification

- Movie Classification: Memprediksi genre-genre yang relevan untuk sebuah film. Sebuah film bisa termasuk dalam lebih dari satu genre, misalnya:

	Name	Year of release	Aired Date	Aired On	Number of Episode	Network	Duration	Content Rating	Synopsis	Cast	Tags	Rank	Rating	Genre
0	Move to Heaven	2021	May 14, 2021	Friday	10	Netflix, Netflix, Netflix	52 min.	18+ Restricted (violence & profanity)	Geu Roo is a young autistic man. He works for ...	Lee Je Hoon, Tang Jun Sang, Hong Seung Hee, Ju...	Autism, Father-Son Relationship, Uncle-Nephew ...	#1	9.2	Life, Drama, Family
1	Hospital Playlist	2020	Mar 12, 2020 - May 28, 2020	Thursday	12	tvN, Netflix, Netflix, Netflix	1 hr. 30 min.	15+ - Teens 15 or older	The stories of people going through their days...	Jo Jung Suk, Yoo Yeon Seok, Jung Kyung Ho, Kim...	Strong Friendship, Doctor, Multiple Mains, Slo...	#2	9.1	Friendship, Romance, Life, Medical
2	Flower of Evil	2020	Jul 29, 2020 - Sep 23, 2020	Wednesday, Thursday	16	tvN	1 hr. 10 min.	15+ - Teens 15 or older	Although Baek Hee Sung is hiding a dark secret...	Lee Joon Gi, Moon Chae Won, Jang Hee Jin, Seo ...	Married Couple, Deception, Suspense, Family Se...	#3	9.1	Thriller, Romance, Crime, Melodrama
3	My Mister	2018	Mar 21, 2018 - May 17, 2018	Wednesday, Thursday	16	tvN	1 hr. 17 min.	15+ - Teens 15 or older	Park Dong Hoon is a middle-aged engineer who i...	Lee Sun Kyun, IU, Park Ho San, Song Sae Byuk, ...	Nice Male Lead, Strong Female Lead, Hardship, ...	#4	9.1	Business, Psychological, Life, Drama, Family
4	Prison Playbook	2017	Nov 22, 2017 - Jan 18, 2018	Wednesday, Thursday	16	tvN, Netflix, Netflix, Netflix	1 hr. 32 min.	15+ - Teens 15 or older	Kim Je Hyuk, a famous baseball player, is arre...	Park Hae Soo, Jung Kyung Ho, Krystal, Im Hwa Y...	Prison, Bromance, Wrongfully Accused, Life Les...	#5	9.1	Comedy, Life, Drama


Machine Learning

Unsupervised Learning

Model unsupervised learning adalah menggunakan algoritma pembelajaran mesin untuk menganalisis dan mengelompokkan kumpulan data historis yang **tidak berlabel**. Algoritma ini menemukan pola tersembunyi atau melakukan pengelompokan data.

Salah satu teknik Unsupervised Learning adalah Clustering. Clustering adalah pengelompokan dataset sedemikian rupa sehingga data dalam kelompok yang sama lebih mirip satu sama lain dibandingkan dengan data dalam kelompok lain.

Contoh: Rekomendasi artikel pada platform media daring seperti Medium, Quora, dll.




Machine Learning

Semi-Supervised Learning

Karena pelabelan data biasanya memakan waktu dan biaya, Anda akan sering memiliki banyak contoh yang tidak berlabel, dan sedikit contoh yang berlabel. Pembelajaran Semi Supervised dapat digunakan untuk membuat semua kumpulan data memiliki label dari beberapa label ini.

Gambar di samping menggambarkan proses di mana:

- Kami melatih model dengan data berlabel.
- Kami menggunakan model terlatih untuk memprediksi label untuk data yang tidak berlabel, yang membuat pseudo-label.
- Kami melatih ulang model dengan pseudo-label dan berlabel secara bersamaan.




Machine Learning

Reinforcement Learning


Komponen Reinforcement Learning:

- **Action** adalah setiap keputusan yang diambil. Misal, saat kita melatih anjing agar bisa membawa bola.
- **Agent** adalah entitas yang membuat keputusan, contohnya adalah perangkat lunak, atau robot, atau bahkan manusia.
- **Environment** adalah sarana untuk berinteraksi, yang dapat menerima action dan memberikan respon berupa hasil maupun data satu set observasi baru.
- **Reward** diberikan saat agent berhasil menyelesaikan tantangan. Mekanisme feedback ini membuat agent belajar tentang tindakan mana yang menyebabkan kesuksesan (menghasilkan reward), atau kegagalan (menghasilkan penalti).



Machine Learning

Machine Learning Workflow




Machine Learning

Data splitting

- Splitting data dalam Machine Learning bertujuan untuk memastikan model yang kita buat apakah dapat menggeneralisasi dengan baik terhadap data baru (data yang belum pernah dilihat sebelumnya).
- **Set pelatihan** adalah subset data yang digunakan untuk melatih model machine learning. Ini adalah data yang digunakan oleh algoritma untuk belajar dan menyesuaikan parameter model.
- **Set validasi** adalah subset data yang digunakan untuk mengukur kinerja dan mengoptimalkan parameter model selama proses pengembangan model. Ini membantu dalam pemilihan model terbaik dan penyetelan parameter.
- **Set pengujian** adalah subset data yang digunakan untuk menguji kinerja model yang telah dikembangkan sepenuhnya. Data yang digunakan adalah data yang belum pernah dilihat sebelumnya.






Training data/validation/test



Machine Learning

Evaluasi Model

- Evaluasi model memberikan wawasan tentang sejauh mana model dapat memahami pola dalam data, membuat prediksi yang akurat, dan melakukan generalisasi pada data yang belum pernah dilihat sebelumnya.
- Evaluasi model dapat membantu memilih model terbaik.
- Evaluasi model juga dapat membantu dalam Perbaikan Model. Jika model memiliki kinerja yang buruk pada matrik evaluasi tertentu, evaluasi dapat memberikan wawasan tentang area yang perlu diperbaiki atau ditingkatkan.

	Underfitting	Just right	Overfitting
Symptoms	- High training error - Training error close to test error - High bias	- Training error slightly lower than test error	- Low training error - Training error much lower than test error - High variance
Regression			
Classification			
Deep learning			
Remedies	- Complexify model - Add more features - Train longer		- Regularize - Get more data

Sumber: <https://aiml.com/what-is-underfitting/>

Evaluasi Model

Overfitting

Overfitting terjadi ketika model **terlalu "menghafal" data latih** sehingga kinerjanya sangat baik pada data latih, tetapi buruk pada data uji atau data baru. Ini terjadi karena model terlalu kompleks dan terlalu sensitif terhadap detail kecil dari data latih (termasuk noise atau outlier).

Ciri-Ciri Overfitting:

- Akurasi tinggi pada **data latih**, tapi akurasi rendah pada **data uji**.
- Model terlalu fokus pada pola-pola kecil yang mungkin **tidak relevan**.
- Terlalu banyak parameter dalam model, menyebabkan model terlalu kompleks.

Cara Mengatasi Overfitting

- **Gunakan Regularisasi:** Tambahkan penalti ke loss function (L1, L2 regularisasi atau Ridge/Lasso).
- **Kurangi kompleksitas model:** Gunakan model yang lebih sederhana (misalnya, Decision Tree dengan kedalaman lebih kecil).
- **Cross-Validation:** Gunakan teknik seperti **k-fold cross-validation**.

Evaluasi Model

Underfitting

Underfitting terjadi ketika model **tidak cukup "cerdas"** untuk mempelajari pola dari data. Artinya, model terlalu sederhana sehingga tidak dapat menangkap hubungan yang mendalam dari data. Akibatnya, model memiliki kinerja buruk pada **data latih** dan **data uji**.

Ciri-Ciri dan Penyebab Underfitting:

- Akurasi rendah pada **data latih** dan **data uji**.
- **Model terlalu sederhana** sehingga tidak mampu mempelajari pola dari data.
- **Jumlah iterasi pelatihan terlalu sedikit** (belum selesai dilatih).
- **Jumlah fitur terlalu sedikit** (fitur penting tidak disertakan).

Cara Mengatasi Underfitting

1. **Tingkatkan kompleksitas model:** Tambahkan beberapa parameter pada model.
2. **Tambahkan lebih banyak fitur:** Tambahkan fitur yang lebih relevan.
3. **Gunakan model yang lebih canggih:** Ganti **linear regression** dengan **decision tree**, **random forest**, atau **neural network**.

Evaluasi Model

Good Fit (Just Right)

Good Fit atau generalisasi yang baik adalah kemampuan model untuk **berkinerja baik pada data baru** yang belum pernah dilihat sebelumnya. Model yang memiliki generalisasi yang baik tidak terlalu "menghafal" data (overfitting) dan tidak terlalu "lupa" pola penting (underfitting).

Ciri-Ciri Generalisasi Baik:

- Akurasi pada **data latih** dan **data uji** hampir sama dan skornya juga tinggi.
- Model mampu menangkap pola umum dari data dengan baik.




Linear Regression

Machine Learning

Linear Regression

- Linear Regression adalah algoritma regresi yang dapat menjelaskan hubungan antara satu variabel dependen (target) dan satu atau lebih variabel independen (fitur) dengan cara mencocokkan persamaan linier dengan data yang diamati.
- Target harus dalam bentuk numerik kontinu seperti harga, berat, dll.
- Simple Linear Regression:** 1 variabel dependen (target) dan 1 variabel independen (fitur).



Machine Learning

Linear Regression

- **Multiple Linear Regression** : 1 variabel dependen (target) dan 2 atau lebih variabel independen (fitur).
- Jika dalam regresi linier kita memodelkan hubungan linear (garis lurus) antara input dan output, maka dalam **polynomial regression**, kita menambahkan derajat polinomial untuk mengakomodasi hubungan yang lebih kompleks atau melengkung (non-linear).

Simple
Linear
Regression

$$y = b_0 + b_1x_1$$


Multiple
Linear
Regression

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$


Polynomial
Linear
Regression

$$y = b_0 + b_1x_1 + b_2x_1^2 + \dots + b_nx_1^n$$

Simple linear model




Polynomial model




Machine Learning


Degree Polynomial Regression



Underfit
High Bias
Low Variance



Correct Fit
Low Bias
Low Variance



Overfit
Low Bias
High Variance

Machine Learning

Evaluasi Model Regresi

Evaluasi model dalam regresi sangat penting untuk memastikan bahwa model yang digunakan menghasilkan prediksi yang akurat dan dapat diandalkan. Ada beberapa metrik evaluasi yang umum digunakan untuk menilai kinerja model. Berikut adalah metrik-metrik evaluasi:

1. **Mean Absolute Error (MAE)**
2. **Mean Squared Error (MSE)**
3. **Root Mean Squared Error (RMSE)**
4. **Mean Absolute Percentage Error (MAPE)**
5. **R2 Score.**

Evaluasi Model

Mean Absolute Error (MAE)

MAE adalah salah satu metrik evaluasi yang paling sederhana dan banyak digunakan. Metrik ini mengukur **rata-rata absolut kesalahan** antara nilai yang diprediksi dan nilai yang sebenarnya.

Penjelasan:

- MAE memberikan gambaran seberapa jauh prediksi rata-rata dari nilai aktual dalam satuan yang sama dengan data asli.
- Semakin kecil nilai MAE, semakin baik model dalam membuat prediksi.
- **Kelebihan:** Mudah dipahami, tidak memperbesar kesalahan besar (karena menggunakan nilai absolut).
- **Kekurangan:** Tidak memberikan penekanan lebih pada kesalahan yang besar.

$$MAE = \frac{1}{n} \sum |y - \hat{y}|$$

Diagram illustrating the MAE formula components:

- $\frac{1}{n}$: Divide by the total number of data points
- $\sum$: Sum of
- y : Actual output value
- $\hat{y}$: Predicted output value
- $|y - \hat{y}|$: The absolute value of the residual

Evaluasi Model

Mean Squared Error (MSE)

MSE mengukur **rata-rata dari kuadrat kesalahan** antara nilai aktual dan nilai prediksi. MSE memberi **penalti lebih besar** pada kesalahan yang lebih besar.

Penjelasan:

- MSE memberikan penalti yang lebih besar terhadap kesalahan yang lebih besar karena kesalahan dikuadratkan.
- **Kelebihan:** Memberikan perhatian lebih pada kesalahan besar, terutama jika kesalahan besar sangat berdampak.
- **Kekurangan:** Sensitif terhadap outlier, sehingga bisa memberikan hasil yang lebih tinggi jika ada kesalahan besar.

$$MSE = \frac{1}{n} \sum \left(\underbrace{y - \hat{y}}_{\substack{\text{The square of the difference} \\ \text{between actual and} \\ \text{predicted}}} \right)^2$$

Evaluasi Model

Root Mean Squared Error (RMSE)

RMSE adalah akar kuadrat dari MSE. Ini mengukur rata-rata kesalahan dalam satuan yang sama dengan data asli, sehingga lebih mudah untuk diinterpretasikan dibandingkan MSE.

Penjelasan:

- RMSE sangat berguna karena mengembalikan kesalahan ke dalam satuan asli data, memudahkan interpretasi dibandingkan MSE.
- **Kelebihan:** Memberikan gambaran yang lebih jelas tentang seberapa jauh prediksi rata-rata dari nilai aktual.
- **Kekurangan:** Sensitif terhadap outlier, sama seperti MSE.

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Evaluasi Model

Mean Absolute Percentage Error (MAPE)

MAPE mengukur kesalahan rata-rata dalam **persentase**. Metrik ini sering digunakan untuk evaluasi peramalan dalam konteks bisnis, karena lebih mudah dipahami oleh non-teknis.

Penjelasan:

- MAPE mengukur rata-rata kesalahan dalam persentase, sehingga memberikan pemahaman yang lebih intuitif tentang seberapa akurat prediksi model.
- **Kelebihan:** Memudahkan interpretasi karena hasilnya dalam persentase.
- **Kekurangan:** MAPE bisa tidak stabil jika nilai aktual sangat kecil

$$MSE = \frac{1}{n} \sum \left(\underbrace{y - \hat{y}}_{\substack{\text{The square of the difference} \\ \text{between actual and} \\ \text{predicted}}} \right)^2$$

Evaluasi Model

R2 Score

- R^2 score mengukur seberapa baik model regresi menjelaskan variasi dalam variabel dependen. Dalam kata lain, ini mengukur seberapa baik variabel prediktor (fitur) dapat menjelaskan perubahan dalam variabel target.
- Nilai $R^2 = 1.0$ berarti model menjelaskan seluruh variasi dalam data, atau prediksi model sangat akurat.
- Nilai $R^2 = 0.0$ berarti model tidak dapat menjelaskan variasi sama sekali, dan model tidak lebih baik dari hanya menggunakan rata-rata data. Contoh:
 - **Rata-rata harga rumah:** \$200,000
 - **Prediksi model:** Model memprediksi semua rumah dengan harga \$200,000, tanpa memperhitungkan fitur lain (seperti ukuran atau jumlah kamar tidur), jadi fitur lain dianggap tidak berkontribusi.
 - **$R^2 = 0.0$:** Model tidak lebih baik daripada memprediksi rata-rata (\$200,000).
- Nilai negatif R^2 terkadang muncul dan ini menunjukkan bahwa model tidak dapat menjelaskan variabilitas data dengan baik, yang berarti model bahkan tidak mengikuti tren data dengan baik dan bisa lebih buruk dari hanya menebak rata-rata nilai target.

Evaluasi Model

R2 Score

Formula

$$R^2 = 1 - \frac{RSS}{TSS}$$

R^2 = coefficient of determination

RSS = sum of squares of residuals

TSS = total sum of squares


$$RSS = \sum (y_i - \hat{y}_i)^2$$

Where: y_i is the actual value and, $\hat{y}_i$ is the predicted value.

$$TSS = \sum (y_i - \bar{y})^2$$

Where: y_i is the actual value and $\bar{y}$ is the mean value of the variable/feature

Gambar perbandingan skor R2





Practice

Colab Link

Visit Here

