

Feature Engineering Part 1

PTP Program





Syarat dan Aturan dalam Pelatihan

Untuk mengikuti materi pelatihan berikut ada beberapa hal yang harus diperhatikan oleh peserta:

- Peserta diharapkan sudah memiliki pengetahuan dasar tentang Data Analysis, Python dan Machine Learning.
- Peserta diharapkan memperhatikan materi dan mencatat materi atau penjelasan yang disampaikan dari instruktur.
- Instruktur diharapkan dapat menjelaskan materi dengan jelas dan memastikan peserta pelatihan dapat memahami topik yang dibahas.
- Materi yang diajarkan sebagian besar adalah praktik atau menggunakan Google Colab (Jupyter Notebook).



Daftar Isi

- Cross Validation
- Pengenalan Feature Engineering
- Jenis-Jenis Feature Engineering
- Feature Scaling & Encoding
- Feature Selection
- Latihan Cara Menerapkan Feature Engineering



Objectives

- Peserta dapat mengetahui apa itu Feature Engineering dan mengapa penting dalam pemodelan machine learning.
- Peserta dapat mengetahui berbagai teknik Feature Engineering.
- Peserta dapat menerapkan berbagai teknik Feature Engineering.
- Peserta dapat menggunakan metode evaluasi untuk memeriksa efek teknik Feature Engineering terhadap kinerja model



Cross Validation

Cross Validation

Apa itu Cross Validation?


Cross-validation adalah teknik untuk mengevaluasi kinerja model dengan membagi dataset menjadi beberapa subset atau lipatan (folds). Ini digunakan untuk memastikan bahwa model yang dibuat tidak hanya mengandalkan satu set data pelatihan saja dan untuk mengurangi risiko overfitting atau underfitting.

Pada umumnya, **k-fold cross-validation** adalah teknik yang paling sering digunakan. Berikut adalah langkah-langkahnya:

1. **Membagi data menjadi k (folds):** Data dibagi menjadi **k** subset yang kira-kira sama besar. Misalnya, dalam **5-fold cross-validation**, dataset dibagi menjadi 5 bagian.
2. **Melatih dan menguji model:** Model dilatih menggunakan **k-1** subset (folds) sebagai data pelatihan, dan diuji pada fold yang tersisa. Proses ini diulang sebanyak **k** kali, setiap kali dengan fold yang berbeda digunakan sebagai data uji.
3. **Menghitung hasil evaluasi:** Setelah **k** iterasi, hasil evaluasi (misalnya, akurasi, MAE, RMSE) dihitung dengan rata-rata dari hasil setiap fold.
4. **Evaluasi model:** Hasil evaluasi ini memberikan gambaran yang lebih akurat tentang seberapa baik model akan bekerja pada data yang belum pernah dilihat sebelumnya.

Cross Validation

Ilustrasi Cross Validation



Sumber Image: <https://medium.com/@ompramod9921/>



Pengenalan Feature Engineering

Feature Engineering

Apa itu Feature Engineering?

Feature Engineering adalah proses menciptakan, memilih, atau mengubah fitur (variabel) dalam dataset untuk meningkatkan kinerja model machine learning. Tujuannya adalah untuk membuat data yang lebih bermakna dan relevan, sehingga model dapat belajar lebih efektif dan menghasilkan prediksi yang lebih akurat.

Kenapa Feature Engineering Penting?

- Data mentah seringkali tidak langsung siap digunakan oleh model machine learning, sehingga kita butuh melakukan rekayasa fitur.
- Model machine learning membutuhkan fitur yang bersih, relevan, dan dalam format yang sesuai untuk belajar sehingga kita butuh melakukan feature engineering (rekayasa fitur)
- Feature Engineering membantu model untuk memahami pola yang lebih dalam dan berfungsi lebih baik dengan data yang lebih tepat.
- Feature Engineering membantu dalam meningkatkan performa model, baik dari sisi kecepatan training data serta hasil prediksi yang lebih baik.

Feature Engineering

Jenis-Jenis Feature Engineering

Ada berbagai teknik dan metode dalam Feature Engineering yang dapat meningkatkan kualitas data dan kinerja model. Berikut adalah jenis-jenis utama dalam Feature Engineering:

- Feature Creation (Pembuatan Fitur Baru)
- Feature Transformation (Transformasi Fitur)
- Feature Selection (Pemilihan Fitur)
- Feature extraction (Ekstraksi Fitur)

Jenis-Jenis Feature Engineering

Feature Creation

Feature Creation melibatkan pembuatan fitur baru yang dapat memberikan informasi tambahan dari data yang ada. Ini dilakukan dengan menggabungkan beberapa fitur atau menciptakan fitur yang lebih informatif.

Contoh:

- Jika kita memiliki fitur **length** (panjang) dan **width** (lebar) untuk sebuah objek, kita dapat membuat fitur baru **area = length * width**.
- Menghitung rasio antara dua fitur, seperti **income_per_capita = income / population**.

Manfaat:

- Membantu model untuk menangkap informasi lebih dalam dari data.
- Membuat fitur yang lebih relevan dan bermakna bagi model.

Jenis-Jenis Feature Engineering

Feature Transformation

Feature Transformation mengubah bentuk atau skala fitur untuk membuatnya lebih mudah dipahami oleh model atau untuk memenuhi asumsi tertentu dalam algoritma.

Contoh:

- **Log Transformation:** Digunakan untuk menangani data dengan distribusi yang miring (skewed distribution). Misalnya, mengubah fitur `income` menjadi `log_income`.
- **Normalization atau Standarisasi (Feature Scaling):** Digunakan untuk membawa fitur ke dalam skala yang seragam, misalnya mengubah nilai fitur agar berada dalam rentang $[0, 1]$ atau mengubahnya menjadi distribusi normal (mean = 0, variance = 1).

Manfaat:

- Mengurangi dampak distribusi yang tidak normal (misalnya, distribusi yang sangat miring).
- Membuat model machine learning lebih stabil dan lebih mudah untuk dipelajari.
- Mempercepat proses training untuk beberapa algoritma machine learning, seperti SVM yang lebih cepat jika kita melakukan feature scaling.

Jenis-Jenis Feature Engineering

Feature Selection

Feature Selection adalah proses memilih subset fitur yang paling relevan dengan target variabel dan menghapus fitur yang kurang informatif atau redundant.

Contoh:

- **Filter Method:** Memilih fitur berdasarkan statistik atau korelasi. Misalnya, menggunakan korelasi Pearson untuk memilih fitur yang berkorelasi dengan target.
- **Wrapper Method:** Memilih fitur dengan membangun model dan mengevaluasi kinerjanya. Teknik seperti *Forward Selection* atau *Backward Elimination* digunakan untuk memilih fitur.
- **Embedded Method:** Pemilihan fitur dilakukan selama proses pelatihan model, seperti *Lasso Regression* yang melakukan seleksi fitur secara otomatis dengan menggunakan regularisasi.

Manfaat:

- Meningkatkan kinerja model dengan menghilangkan fitur yang tidak relevan atau redundan.
- Mencegah overfitting dengan mengurangi jumlah fitur yang digunakan dalam model.

Jenis-Jenis Feature Engineering

Feature Extraction

Feature Extraction adalah teknik untuk mengubah atau menggabungkan fitur-fitur yang ada menjadi fitur baru yang lebih bermakna dan informatif, dengan tujuan untuk menyederhanakan data atau menangkap informasi yang lebih penting. Proses ini mirip seperti Feature Transformation dan Feature Creation, namun tujuan utamanya adalah untuk mengurangi dimensi data, tetapi tetap mempertahankan informasi yang berguna. Ini berbeda dengan Feature Selection yang berfokus pada memilih fitur yang sudah ada.

Contoh:

- **Principal Component Analysis (PCA):** teknik yang digunakan untuk mengurangi dimensi data dengan mengubah fitur asli menjadi kumpulan fitur yang lebih kecil yang disebut principal components. Misalkan kita memiliki dataset yang berisi fitur-fitur dari data pelanggan, seperti usia, pendapatan, skor kredit, dll., dan kita ingin mengurangi dimensi data sambil tetap mempertahankan informasi penting.
- **Linear Discriminant Analysis (LDA):** teknik ini digunakan untuk mengurangi dimensi data dan juga digunakan untuk klasifikasi. Berbeda dengan PCA yang tidak mempertimbangkan kelas target, LDA memfokuskan pada pemisahan antar kelas.



Feature Scaling & Encoding

Feature Scaling

Apa itu Feature Scaling?

Feature Scaling merupakan teknik yang tergolong dalam transformasi fitur. Teknik ini adalah teknik yang digunakan untuk menstandarisasi atau menormalisasi data sehingga fitur-fitur dalam dataset memiliki skala yang seragam. Hal ini penting karena banyak algoritma pembelajaran mesin (seperti regresi linear, k-means, dan lainnya) lebih efektif dan efisien ketika fitur-fitur mereka berada dalam skala yang serupa.

Kenapa Feature Scaling itu Penting?


- **Algoritma Sensitif terhadap Skala Fitur:** Beberapa algoritma seperti **Linear Regression**, **K-Nearest Neighbors (KNN)**, **Support Vector Machines (SVM)**, **Gradient Descent**, dan **K-means** sangat sensitif terhadap skala fitur.
- **Mempercepat Konvergensi:** Pada beberapa algoritma, seperti **Gradient Descent**, scaling dapat membantu dalam mempercepat konvergensi.
- **Memperbaiki Kinerja Model:** Model yang dilatih dengan data yang sudah di-scaling sering memberikan hasil yang lebih baik.

Feature Scaling

Jenis-Jenis Feature Scaling

Meskipun sebagian besar algoritma pembelajaran mesin sensitif terhadap skala, penskalaan Fitur tidak penting untuk algoritma berbasis pohon (Tree) seperti Random Forest atau Decision Tree yang penskalaannya invarian. Feature scaling tidak mempengaruhi kinerja model yang dilatih menggunakan algoritma ini.

Ada beberapa metode populer untuk Penskalaan Fitur seperti MinMaxScaler, StandardScaler, dan RobustScaler.



Feature Scaling

MinMaxScaler

MinMaxScaler merubah data sehingga berada dalam rentang tertentu, biasanya [0, 1], dengan rumus sebagai berikut:

$$X_{new} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- X = nilai asli fitur
- Xmin = nilai minimum dari fitur
- Xmax= nilai maksimum dari fitur

Kapan digunakan:

- Digunakan ketika distribusi data **tidak mengikuti distribusi normal**.
- Cocok untuk algoritma seperti **Neural Networks, K-Means Clustering, SVM**, dan lain sebagainya.

Feature Scaling

StandardScaler

Standardization menskalakan data sehingga memiliki mean = 0 dan standar deviasi = 1. Ini dilakukan dengan mengurangi mean dan membagi dengan standar deviasi dari setiap fitur.

$$X' = \frac{X - \text{Mean}}{\text{Standard deviation}}$$

Kapan digunakan:

- Digunakan ketika distribusi data mengikuti **distribusi normal**.
- Cocok untuk algoritma yang menggunakan perhitungan jarak seperti **KNN**, **SVM**, dan **Logistic Regression**.

Feature Scaling

RobustScaler

RobustScaler menggunakan median dan interquartile range (IQR) untuk mengurangi pengaruh nilai pencilan (outlier). Dengan ini, skala data menjadi lebih tahan terhadap pencilan (outlier).

$$X_{robust} = \frac{X - X_{median}}{X_{75th} - X_{25th}}$$

x_{75} disebut juga sebagai Q3, x_{25} disebut juga Q1, dan $x_{75} - x_{25}$ disebut juga sebagai IQR (Interquartile Range).

Kapan digunakan:

- Digunakan ketika data mengandung pencilan (outlier) yang dapat mempengaruhi model secara signifikan.
- Cocok untuk dataset dengan pencilan yang tidak dapat dihapus atau yang memiliki nilai ekstrim.

Encoding

Apa itu Encoding?

Encoding adalah teknik yang digunakan untuk mengubah data kategorikal (non-numerik) menjadi format numerik agar dapat digunakan oleh algoritma pembelajaran mesin yang biasanya hanya menerima input berupa data numerik.

Data kategorikal, seperti teks, label, atau kategori, sering ditemukan dalam banyak dataset, misalnya status perkawinan, jenis kelamin, negara, atau kelas produk. Encoding memungkinkan model untuk memproses dan memanfaatkan data kategorikal ini.

Jenis-jenis encoding yang umumnya digunakan:

- Label Encoding
- One-Hot Encoding
- Ordinal Encoding

Jenis Encoding

Label Encoding & Ordinal Encoding

Label Encoding mengubah setiap kategori dalam fitur atau target (label) menjadi angka integer yang unik. Misalnya, kategori ['Anjing', 'Kucing', 'Kuda'] dapat diubah menjadi [0, 1, 2].

Ordinal Encoding adalah metode untuk mengubah kategori yang memiliki **urutan (ordinal)** menjadi angka dengan mempertahankan urutan tersebut. Misalnya, kategori ['Rendah', 'Sedang', 'Tinggi'] dapat diubah menjadi [0, 1, 2].

Perbedaan Label Encoding dan Ordinal Encoding:

- Label Encoding umumnya digunakan untuk target dalam kasus klasifikasi dan tidak memperhatikan urutan.
- Ordinal Encoding umumnya digunakan untuk fitur dengan memperhatikan urutan (ordinal).

Jenis Encoding

Label Encoding & Ordinal Encoding

Kelebihan Ordinal Encoding:

- Ordinal Encoding menghasilkan fitur dengan **dimensi tunggal**, sehingga lebih hemat memori dibandingkan **One-Hot Encoding** yang menambah dimensi data.
- Cocok untuk dataset besar atau saat bekerja dengan model yang sensitif terhadap jumlah fitur.
- Model seperti Decision Tree, Random Forest, dan Gradient Boosting dapat bekerja dengan baik meskipun menggunakan Ordinal Encoding.

Kekurangan Ordinal Encoding:

- Model yang berbasis jarak atau linear seperti **KNN**, **SVM**, atau **Linear Regression** mungkin memberikan hasil yang bias karena menyalahartikan hubungan antar kategori.
- Dalam regresi linier, penggunaan Ordinal Encoding terkadang dapat menyebabkan **multikolinearitas**, terutama jika ada banyak kategori yang berhubungan satu sama lain.
- Pada dataset dengan jumlah kategori yang besar, Ordinal Encoding dapat membuat model **overfitting** pada kategori tertentu karena nilai numerik memberikan bobot yang tidak sesuai.

Jenis Encoding

One-Hot Encoding

One-Hot Encoding mengubah setiap kategori dalam fitur menjadi kolom terpisah dan memberikan nilai 1 jika kategori tersebut ada di baris tertentu, atau 0 jika tidak ada.

Color	Red	Yellow	Green
Red	1	0	0
Red	1	0	0
Yellow	0	1	0
Green	0	0	1
Yellow	0	1	0

kategori ['Red', 'Green', 'Blue'] akan diubah menjadi tiga kolom, satu untuk setiap kategori.

Kelebihan OneHotEncoder:

- Tidak ada urutan atau peringkat yang diterapkan pada kategori.
- Cocok untuk data kategorikal nominal.
- Model seperti **KNN**, **SVM** dan **Neural Networks** umumnya bekerja lebih baik dengan fitur yang telah di One-Hot Encoder karena mereka tidak sensitif terhadap urutan numerik.

Jenis Encoding

One-Hot Encoding

Kekurangan OneHotEncoder:

- Dapat menyebabkan banyak kolom baru jika fitur memiliki banyak kategori, yang dapat meningkatkan kompleksitas model (known as "**curse of dimensionality**").
- Kurang baik untuk Decision Trees, karena Decision Tree secara alami mampu menangani data kategorikal tanpa perlu One-Hot Encoding. Ketika menggunakan One-Hot Encoding, dimensi data meningkat, tetapi pohon keputusan tetap membagi data berdasarkan nilai numerik atau kategorikal asli.
- Seringkali fitur One-Hot akan memiliki **informasi redundan**, sehingga beberapa cabang pohon dapat menjadi tidak optimal.
- One-Hot Encoding dapat menyebabkan **multikolinearitas**. Jika semua kategori di-encode ke dalam kolom One-Hot tanpa menghapus satu kolom referensi (dummy variable trap), maka ada korelasi sempurna antara kolom-kolom tersebut dan menyebabkan koefisien regresi menjadi tidak stabil dan sulit untuk diinterpretasikan.




Feature Selection

Feature Selection

Teknik Feature Selection

Gambar berikut ini adalah panduan yang dapat anda gunakan untuk pemilihan teknik untuk seleksi fitur. Input variable adalah kondisi fitur apakah numerik atau kategori, sedangkan output variable adalah targetnya apakah numerik (regresi) atau kategori (klasifikasi)



Sumber: <https://machinelearningmastery.com/>



External References (Practice)

Colab Link

[Visit Here](#)



Hacktiv8id



Hacktiv8id



Hacktiv8



Hacktiv8 Indonesia