

Feature Engineering Part 2

PTP Program





Syarat dan Aturan dalam Pelatihan

Untuk mengikuti materi pelatihan berikut ada beberapa hal yang harus diperhatikan oleh peserta:

- Peserta diharapkan sudah memiliki pengetahuan dasar tentang Statistika, Machine Learning dan Feature Engineering .
- Peserta diharapkan memperhatikan materi dan mencatat materi atau penjelasan yang disampaikan dari instruktur.
- Instruktur diharapkan dapat menjelaskan materi dengan jelas dan memastikan peserta pelatihan dapat memahami topik yang dibahas.
- Materi yang diajarkan sebagian besar adalah praktik atau menggunakan Google Colab (Jupyter Notebook).



Daftar Isi

- Menangani High Cardinality
- Menangani Missing Values
- Menangani Outlier



Objectives

- Peserta dapat mengetahui apa itu High Cardinality dan cara menanganinya.
- Peserta dapat mengetahui cara menangani missing values.
- Peserta dapat mengetahui cara mendeteksi dan menangani outlier.



Mengenai High Cardinality

High Cardinality

Apa itu High Cardinality?

High Cardinality (Kardinalitas Tinggi) mengacu pada situasi di mana sebuah fitur atau kolom dalam dataset memiliki sejumlah besar nilai unik. Ini sering terjadi pada kolom yang berisi data kategori, seperti nomor telepon, kode produk dan nama wilayah.

Jika kita menerapkan **One-Hot Encoding** pada fitur dengan high cardinality, akan ada banyak kolom baru yang diciptakan. Ini bisa menyebabkan **curse of dimensionality**, di mana model menjadi sulit untuk dilatih dan memiliki risiko **overfitting**. Selain itu juga dapat memperlambat pelatihan model dan meningkatkan kebutuhan memori serta waktu pemrosesan.

Salah satu cara untuk melihat Cardinality adalah dengan menggunakan fungsi `.nunique()` pada pandas dataframe. Menggunakan fungsi tersebut kita dapat mengetahui jumlah nilai unik pada setiap kategori.

Untuk menangani fitur-fitur yang memiliki kardinalitas tinggi adalah dengan *Feature Creation* dengan teknik seperti **Target Encoding**, **Frequency Encoding**, **Splitting Feature**, dan masih banyak lagi.

High Cardinality

Target Encoding

Target Encoding adalah proses mengganti kategori fitur dengan rata-rata nilai target pada setiap kategori.

Misalkan kita punya fitur Kota dengan targetnya adalah Pendapatan. Kita dapat mengelompokkan kota berdasarkan rata-rata pendapatannya kemudian kita skalakan untuk kategori dengan rata-rata terendah menjadi 0. Hal ini dapat mengurangi jumlah dimensi dibandingkan kita melakukan encoding dengan One Hot Encoder.

Kapan gunakan teknik ini:

- Data kategori dengan **high cardinality**.
- Ketika kategori fitur memiliki hubungan kuat dengan target variabel.

Kota	Pendapatan	Kota_Encoded
Jakarta	70,000	2
Bandung	50,000	0
Jakarta	75,000	2
Surabaya	60,000	1
Bandung	55,000	0
Surabaya	65,000	1
Jakarta	80,000	2
Bandung	52,000	0
Surabaya	68,000	1

High Cardinality

Frequency Encoding

Frequency Encoding adalah teknik encoding untuk data kategori di mana setiap kategori digantikan dengan frekuensi atau proporsi kemunculannya dalam dataset.

Misalkan kita punya fitur Kota dengan targetnya adalah Pendapatan. Kita dapat mengelompokkan kota berdasarkan frekuensi kemunculannya tanpa mempertimbangkan target. Namun teknik ini mungkin kurang baik dibandingkan Target Encoding.

Kapan Digunakan:

- Ketika fitur kategori memiliki jumlah kategori yang tinggi.
- Sebagai langkah awal sebelum mencoba teknik encoding lain.

Kota	Pendapatan	Kota_Encoded
Jakarta	70,000	3
Bandung	50,000	2
Jakarta	75,000	3
Surabaya	60,000	2
Bandung	55,000	2
Surabaya	65,000	2
Jakarta	80,000	3

High Cardinality

Splitting Feature

Terkadang, suatu fitur dari suatu dataset berisi beberapa bagian informasi, dan perlu dipecah menjadi kolom-kolom terpisah untuk representasi dan analisis yang lebih baik. Dengan mengekstraksi dan membuat fitur-fitur yang lebih bermakna dapat menghasilkan kinerja yang lebih baik dengan mengungkap informasi potensial..

Misalkan terdapat fitur Date yang dapat dipecah menjadi dua fitur, yaitu fitur Year dan Month.

	Date	Price	year	month
0	1987-05-20	18.63	1987	5
1	1987-05-21	18.45	1987	5
2	1987-05-22	18.55	1987	5
3	1987-05-25	18.60	1987	5
4	1987-05-26	18.63	1987	5

Kapan Digunakan:

- Saat fitur memiliki informasi komposit yang dapat dipisahkan.
- Saat fitur kategori memiliki jumlah kategori yang sangat tinggi (high cardinality).
- Untuk meningkatkan interpretabilitas dan analisis.

High Cardinality

Manual Binning (Discretization)

Teknik ini adalah teknik yang mengelompokkan data berdasarkan pengetahuan domain atau logika tertentu.

Contoh:

- Hari kerja (weekday): Senin, Selasa, Rabu, Kamis, Jumat.
- Akhir pekan (weekend): Sabtu, Minggu.

Kapan Teknik Ini Digunakan?

- Saat Anda ingin menyederhanakan fitur kategori dengan banyak nilai unik.
- Saat anda ingin membuat data lebih terstruktur tanpa kehilangan informasi yang signifikan.

	Candy Variety	Day	Type of Day
0	Chocolate Hearts	Sunday	Weekend
1	Sour Jelly	Saturday	Weekend
2	Candy Canes	Friday	Weekday
3	Sour Jelly	Sunday	Weekend
4	Fruit Drops	Sunday	Weekend
5	Sour Jelly	Thursday	Weekday



Menangani Missing Values

Missing Values

Apa itu Missing Values?

Missing values atau nilai yang hilang adalah kondisi di mana data tidak lengkap karena beberapa entri tidak tercatat atau tidak tersedia. Dalam analisis data, missing values sering kali terjadi, dan jika tidak ditangani dengan baik, hal ini dapat mempengaruhi kinerja model, akurasi analisis, dan pengambilan keputusan.

Penyebab Missing Values

1. **Kesalahan Pengumpulan Data:** Data hilang karena kesalahan saat pengumpulan data.
2. **Kesalahan Pengolahan:** Kesalahan saat mentransformasikan atau memanipulasi data.
3. **Tidak Tersedia:** Data tidak dapat diperoleh atau tidak relevan.
4. **Sengaja Dikosongkan:** Beberapa nilai mungkin sengaja dibiarkan kosong oleh pihak yang mengumpulkan data.

Missing Values

Teknik Menangani Missing Values

Ada beberapa teknik dasar yang umumnya digunakan untuk menangani missing values, diantaranya yaitu:

1. Menghapus Baris atau Kolom yang memiliki Missing Values (Deletion).

Kapan diterapkan:

- Jika jumlah missing values relatif kecil dan tidak mempengaruhi analisis secara signifikan.
- Jika data hilang tersebar secara acak, dan menghapus baris atau kolom tidak akan mengurangi informasi yang berharga.

Keuntungan:

- Menjaga integritas data dan model tetap sederhana.

Kekurangan:

- Jika terlalu banyak data yang hilang, menghapus baris atau kolom dapat menyebabkan kehilangan informasi yang penting.

Missing Values

Teknik Menangani Missing Values

2. Mengisi Nilai yang Hilang dengan Mean/Median/Mode (Imputation)

Kapan Digunakan:

- Ketika data hilang values cukup banyak ($\leq 20\%$)
- Ketika distribusi data normal anda bisa gunakan Mean atau Median.
- Ketika distribusi data tidak normal atau memiliki outlier sebaiknya gunakan Median.
- Ketika data kategorikal bisa gunakan Mode atau most frequent.

Keuntungan:

- Mudah dilakukan dan cepat.
- Mengisi data hilang tanpa menghapus informasi lainnya.

Kekurangan:

- Dapat mengurangi variabilitas data.
- Dapat mengakibatkan bias.

Missing Values

Teknik Menangani Missing Values

3. Menghapus Kolom (Drop Columns)

Kapan Digunakan:

- Ketika sebuah kolom memiliki terlalu banyak nilai yang hilang (misalnya, lebih dari 20-30% dari total jumlah data).
- Ketika kolom tersebut mengandung data yang tidak dapat diandalkan.

Keuntungan:

- Meningkatkan kualitas data dengan menghapus kolom yang tidak memberikan informasi penting.
- Menghindari potensi bias yang dapat terjadi jika data yang hilang terlalu banyak diimputasi.

Kekurangan:

- Mengurangi jumlah informasi yang tersedia, yang dapat mempengaruhi hasil analisis atau model.
- Bisa mengabaikan data yang sebenarnya relevan jika kriteria penghapusan tidak diperhitungkan dengan baik.



Menangani Outlier

Outlier

Apa itu Outlier?

Outlier adalah suatu pengamatan yang menyimpang begitu jauh dari pengamatan lainnya sehingga menimbulkan kecurigaan bahwa pengamatan tersebut dihasilkan oleh mekanisme yang berbeda.

Berikut beberapa penyebab terjadinya outlier:

1. **Kesalahan Pencatatan Data:** Kesalahan manusia seperti yang terjadi selama pengumpulan data, pencatatan, atau entri data dapat menyebabkan terjadinya outlier.
2. **Kesalahan Pengukuran (Kesalahan Instrumen):** Terjadi ketika instrumen pengukuran yang digunakan ternyata rusak atau tidak berfungsi dengan baik.
3. **Kesalahan yang Sengaja Dibuat:** Outlier yang dibuat dengan sengaja untuk pengujian metode deteksi outlier.
4. **Kesalahan Pengolahan Data:** Manipulasi data atau perubahan data yang tidak sengaja dapat menyebabkan outlier.
5. **Kesalahan Sampling:** Pengambilan atau pencampuran data dari sumber yang salah atau beragam.
6. **Natural Error:** Bukan kesalahan yang dibuat atau disengaja, melainkan peristiwa alami dalam data. Sebagian besar data dunia nyata termasuk dalam kategori ini. Contohnya: Lonjakan Penjualan di Musim Liburan, Kenaikan atau Penurunan Harga yang Drastis, dan lainnya.

Outlier

Handling Outlier

Outlier tidak selalu perlu dihapus; perlakuannya sangat tergantung pada konteks dan jenis analisis atau model yang digunakan. Berikut adalah pertimbangan utama untuk memutuskan apakah outlier perlu dihapus atau tidak:

1. Outlier harus diselidiki dan dipertahankan untuk kasus seperti berikut:

- a. **Peramalan Pendapatan:** Lonjakan atau penurunan yang tidak biasa dalam pendapatan mungkin bukan kesalahan, melainkan peristiwa signifikan (seperti peluncuran produk, kampanye pemasaran, atau perubahan ekonomi). Outlier ini harus diperiksa dengan cermat karena bisa memberikan wawasan berharga tentang tren bisnis atau pasar.
- b. **Deteksi Penipuan:** Pada kasus transaksi kartu kredit, outlier (seperti transaksi yang tidak biasa atau besar) dapat menunjukkan aktivitas penipuan. Mengidentifikasi outlier ini bisa membantu dalam membangun model deteksi penipuan atau menandai aktivitas yang mencurigakan.

Outlier

Handling Outlier

2. Outlier harus dihapus atau ditangani ketika:

- a. **Kesalahan Data:** Jika outlier disebabkan oleh kesalahan entri data, kesalahan pengukuran, atau masalah lain yang tidak mencerminkan sifat sebenarnya dari data, maka sebaiknya dihapus. Outlier ini bisa merusak model atau analisis yang dilakukan.
- b. **Sensitivitas Algoritma:** Beberapa algoritma pembelajaran mesin, terutama yang berbasis jarak (seperti KNN, atau algoritma yang mengasumsikan distribusi normal seperti regresi linier), dapat sangat terpengaruh oleh outlier. Outlier dapat menyebabkan model berperilaku tidak semestinya atau menghasilkan prediksi yang tidak akurat. Dalam kasus seperti ini, menghapus atau menangani outlier (misalnya melalui transformasi atau pembatasan nilai) sering diperlukan agar algoritma berfungsi dengan baik.

Outlier

Handling Outlier

Berikut adalah **Algoritma yang Sensitif Terhadap Outliers**:

1. **Model Linear (Regresi Linear, Regresi Logistik)**: Dalam regresi linear, setiap koefisien mengindikasikan pengaruh variabel input terhadap prediksi output. Outliers dapat menyebabkan koefisien regresi berubah, sehingga bisa membuat **prediksi yang tidak akurat**.
2. **Algoritma yang Menggunakan Jarak dalam Perhitungan (misalnya KNN, KMeans, SVM)**: Algoritma yang menghitung jarak antara data titik sangat terpengaruh oleh outliers. Misalnya, dalam **KNN**, jika ada titik data yang jauh dari yang lain, itu dapat mengubah hasil tetangga terdekatnya dan mempengaruhi klasifikasi atau prediksi.
3. **Neural Networks**: Beberapa penelitian menunjukkan bahwa **Neural Networks** dapat sensitif terhadap outliers, terutama jika jumlah outliers tinggi dan deviasinya besar. Karena Neural Networks belajar dari distribusi data dan outliers dapat mengubah pola yang dipelajari oleh jaringan, ini dapat mempengaruhi performa model.

Outlier

Handling Outlier

Algoritma yang Tidak Sensitif Terhadap Outliers:

1. **Algoritma Berbasis Pohon (Decision Tree, Random Forest, XGBoost, dll.):** Algoritma berbasis pohon seperti **Decision Tree**, **Random Forest**, dan **XGBoost** cenderung lebih robust terhadap outliers. Hal ini karena model pohon membuat keputusan berdasarkan pembagian data ke dalam simpul berdasarkan nilai ambang batas, sehingga outliers sering kali hanya mempengaruhi beberapa cabang pohon dan tidak merusak keseluruhan model.
2. **Naive Bayes:** Algoritma juga cukup tahan terhadap outliers karena model ini mengasumsikan independensi antar fitur dan menghitung probabilitas berdasarkan distribusi data. Outliers tidak secara signifikan mempengaruhi hasil prediksi jika data lainnya lebih dominan dalam menentukan probabilitas.

Outlier

Cara Deteksi Outlier

Cara deteksi outlier ?

1. Untuk Distribusi Normal/Gaussian


→ Gunakan Z-Scores

$$\text{Outliers} = \text{mean} \pm 3 \cdot \text{std}$$

→ Nilai yang berada di luar mean plus atau minus 3 kali standar deviasi variabel dianggap outlier.

Detecting Outliers with z-Scores

An **outlier** is an extremely large or extremely small data value relative to the rest of the data set. It may represent a data entry error, or it may be genuine data.



Outlier


Cara Deteksi Outlier

2. Untuk Distribusi Skew atau miring
 - Pendekatan umum adalah menghitung kuantil, dan kemudian Rentang Interkuartil (IQR), sebagai berikut:

$$IQR = 75th \text{ quartile} - 25th \text{ quartile}$$
 - Nilai outlier akan berada di luar batas atas dan bawah seperti berikut:

$$\begin{aligned} \text{Upper boundary} &= 75th \text{ quartile} + (IQR * 1.5) \\ \text{Lower boundary} &= 25th \text{ quartile} - (IQR * 1.5) \end{aligned}$$
 - Untuk kasus ekstrim:

$$\begin{aligned} \text{Upper boundary} &= 75th \text{ quartile} + (IQR * 3) \\ \text{Lower boundary} &= 25th \text{ quartile} - (IQR * 3) \end{aligned}$$



Outlier

Teknik Menangani Outlier

Berikut adalah beberapa teknik untuk menangani outlier:

1. Trimming (Penghapusan)

- **Definisi:** Trimming adalah teknik di mana kita **menghapus** outlier dari dataset. Outliers dianggap tidak relevan atau distorsi, dan kita menghapus nilai-nilai yang sangat berbeda dari distribusi data lainnya.
- **Kapan digunakan:** Ketika outlier disebabkan oleh kesalahan pengukuran, kesalahan entri data, atau kesalahan lainnya yang tidak dapat dijelaskan.
- **Keuntungan:** Dapat memperbaiki kinerja model, terutama jika algoritma yang digunakan sensitif terhadap outliers, seperti regresi linear.
- **Contoh:** Jika kita mendeteksi outlier di dalam dataset, kita dapat menghapusnya dengan menggunakan metode tertentu, seperti menggunakan batas z-score atau nilai percentile (misalnya, lebih dari 99 persen data).

Outlier

Teknik Menangani Outlier

2. Treating Outliers as Missing Data (Menangani Outlier sebagai Data yang Hilang)

- **Definisi:** Dalam pendekatan ini, kita tidak menghapus outlier, tetapi menggantinya dengan nilai **NaN** atau **missing value**. Kemudian, kita dapat menggunakan teknik imputasi (pengisian data yang hilang) untuk mengganti nilai-nilai yang hilang ini. Secara sederhana kita dapat mengartikan bahwa kita ubah outlier menjadi nilai imputasi, seperti mean ataupun median.
- **Kapan digunakan:** Jika kita ingin mempertahankan informasi mengenai adanya outlier dalam analisis atau model, tetapi tidak ingin nilai outlier terlalu mempengaruhi proses pelatihan atau prediksi.
- **Keuntungan:** Tidak menghapus informasi dan memberi kesempatan untuk menilai atau menangani outlier lebih lanjut.
- **Contoh:** Kita mendeteksi outlier dan mengganti nilai-nilai tersebut dengan **NaN**, lalu menggunakan metode imputasi seperti mean imputation atau median imputation untuk mengganti nilai yang hilang.

Outlier

Teknik Menangani Outlier

3. Censoring (Capping) (Pembatasan Nilai)

- **Definisi:** Censoring atau capping adalah teknik di mana kita membatasi nilai-nilai outlier dengan menetapkan nilai maksimum dan/atau minimum pada distribusi data. Dengan kata lain, kita "membatasi" nilai outlier ke ambang batas tertentu.
- **Kapan digunakan:** Ketika kita ingin menjaga nilai-nilai ekstrim untuk tetap ada dalam data, namun membatasi dampaknya pada model atau analisis.
- **Keuntungan:** Mempertahankan informasi tentang outlier, tetapi mengurangi pengaruhnya pada analisis atau model.
- **Contoh:** Jika data memiliki rentang nilai dari 1 hingga 1000, kita dapat mengatur batas capping seperti 95 percentile untuk nilai maksimum dan 5 percentile untuk nilai minimum. Semua nilai yang melebihi batas-batas ini akan dipotong atau dibatasi pada nilai tersebut.
- **Catatan:** Capping juga dikenal dengan istilah **Winsorization** atau **top/bottom coding**. Capping hanya cocok untuk situasi di mana outliers tidak sepenuhnya salah, tetapi nilai yang terlalu ekstrim bisa merusak model.



External References (Practice)

Colab Link

[Visit Here](#)



Hacktiv8id



Hacktiv8id



Hacktiv8



Hacktiv8 Indonesia