

Regularization & Classification

PTP Program





Syarat dan Aturan dalam Pelatihan

Untuk mengikuti materi pelatihan berikut ada beberapa hal yang harus diperhatikan oleh peserta:

- Peserta diharapkan sudah memiliki pengetahuan dasar tentang Data Analysis, Machine Learning dan Dasar Feature Engineering .
- Peserta diharapkan memperhatikan materi dan mencatat materi atau penjelasan yang disampaikan dari instruktur.
- Instruktur diharapkan dapat menjelaskan materi dengan jelas dan memastikan peserta pelatihan dapat memahami topik yang dibahas.
- Materi yang diajarkan sebagian besar adalah praktik atau menggunakan Google Colab (Jupyter Notebook).



Daftar Isi

- Regularization
- Logistic Regression
- Evaluasi Model Pada Tugas Klasifikasi
- Hands-On



Objectives

- Peserta dapat mengetahui apa itu Regularization.
- Peserta dapat mengetahui apa Logistic Regression dan cara kerjanya.
- Peserta dapat membuat pemodelan machine learning dengan Logistic Regression
- Peserta dapat memahami cara mengevaluasi model untuk tugas klasifikasi.



Regularization

Regularization

Apa itu Regularization?


Dalam melatih model, ada dua masalah utama:

- **Overfitting:** Terjadi ketika model bekerja dengan sangat baik pada data pelatihan, tetapi tidak berkinerja baik pada data uji.
- **Underfitting:** Terjadi ketika model tidak berkinerja baik pada data pelatihan maupun data uji.

Regularisasi digunakan untuk menghindari masalah overfitting, yang muncul ketika model terlalu rumit dan terlalu cocok dengan data pelatihan.

Teknik-teknik **regularisasi** meliputi:



- **Lasso Regression**
- **Ridge Regression**
- **Elastic Net**



Regularization

Ridge Regression (L2)

Ridge Regression adalah metode **regulasi** yang menggunakan **L2 regularization**. Metode ini bertujuan untuk mengurangi **overfitting** dengan menambahkan **penalty term** pada fungsi biaya (**cost function**). Ridge Regression mencegah koefisien variabel menjadi terlalu besar, tetapi **tidak mengecilkan koefisien menjadi nol**.



$$\text{Cost function} = \text{Loss} + \lambda \times \sum \|w\|^2$$

Here,

Loss = Sum of the squared residuals

λ = Penalty for the errors

W = slope of the curve/ line

Sumber: <https://www.andreaperlato.com/theorypost/ridge-and-lasso-regression/>

Regularization

Ridge Regression (L2)

Keunggulan Ridge Regression

1. **Dapat Mengatasi Multikolinieritas**

Ridge Regression dapat mengatasi masalah **multikolinieritas** (fitur yang saling berkorelasi) dengan membagi pengaruh antar fitur yang berkorelasi, sehingga memberikan bobot kecil pada masing-masing fitur.

2. **Mengurangi Dampak Fitur yang Tidak Relevan**

Ridge Regression mengurangi pengaruh fitur yang tidak relevan dalam analisis, meskipun tidak mengecilkannya hingga nol seperti Lasso.

3. **Cocok Jika Semua Fitur Penting**

Ridge cocok jika Anda ingin mempertahankan semua fitur karena metode ini hanya mengecilkan koefisien fitur tanpa menghapusnya.

Regularization

Ridge Regression (L2)

Kekurangan Ridge Regression

1. **Terpengaruh Masalah Standar Regresi**

Ridge Regression tetap terpengaruh oleh masalah asumsi model, interaksi antar variabel, dan outlier seperti pada model regresi standar (linear regression tanpa regularisasi)


2. **Koefisien Tidak Menjadi Nol**

Berbeda dengan Lasso Regression, Ridge hanya mendekatkan koefisien ke nol tetapi **tidak memaksa koefisien menjadi nol**. Hal ini membuatnya tidak bisa melakukan seleksi fitur otomatis.

Regularization

Lasso Regression (L1)

Lasso Regression sering disebut sebagai **L1 regularization**. Teknik ini mirip seperti Ridge Regression yaitu menambahkan **penalty term** ke dalam fungsi biaya (cost function), namun teknik ini dapat menyebabkan beberapa koefisien menjadi nol, yang berarti model mengabaikan fitur yang sesuai. Ini berguna untuk pemilihan fitur.



$$\text{Cost function} = \text{Loss} + \lambda \times \sum ||w||$$

Here,

Loss = Sum of the squared residuals

λ = Penalty for the errors

w = slope of the curve/ line

Slope tidak dikuadratkan seperti Ridge

Sumber: <https://www.andreaperlato.com/theorypost/ridge-and-lasso-regression/>

Regularization

Lasso Regression (L1)

Keunggulan Lasso Regression:

1. **Seleksi Fitur Otomatis:**
Lasso dapat mengurangi koefisien tertentu menjadi nol, sehingga secara efektif melakukan seleksi fitur.
2. **Menghilangkan Variabel yang Tidak Perlu:**
Berguna jika dataset mengandung banyak variabel independen yang tidak diperlukan atau redundan.
3. **Menangani Multikolinieritas:**
Lasso memilih satu fitur dan mengecilkan koefisien fitur lain yang berkorelasi menjadi nol.

Kekurangan Lasso Regression:

1. **Tidak Ideal jika Semua Variabel Penting:**
Jika Anda yakin semua variabel independen penting dan relevan, Lasso mungkin bukan pilihan terbaik.
2. **Tidak Stabil pada Dataset Kecil:**
Lasso bisa menjadi tidak stabil jika jumlah sampel kecil atau jumlah fitur mendekati jumlah sampel.
3. **Lambat pada Dataset Besar:**
Lasso bisa lebih lambat dibandingkan metode lain saat berhadapan dengan dataset yang besar.

Regularization

Contoh L1 & L2

Gambar disamping adalah contoh perbedaan Error antara Standard Linear Regression (tanpa regularisasi), Lasso dan Ridge dalam sebuah dataset. Kita bisa menyimpulkan bahwa dengan regularisasi kita dapat meminimalkan Error atau Cost Function dengan menyesuaikan posisi garis linear.


Lasso

$$\text{Penalty} = \lambda * |\text{slope}|$$

Ridge

$$\text{Penalty} = \lambda * (\text{slope})^2$$

* Note: λ controls how aggressively the model makes changes.



* Our Data was actually "parabolic" but we couldn't tell from the small training sample.




Logistic Regression

Logistic Regression

Apa itu Logistic Regression?

Logistic Regression adalah salah satu algoritma **Machine Learning** yang digunakan untuk **klasifikasi**. Meskipun namanya mengandung kata "regression", tujuannya bukan untuk memprediksi nilai kontinu (seperti pada **linear regression**), tetapi untuk memprediksi probabilitas dari suatu kejadian atau kelas tertentu. Logistic Regression adalah fondasi dari banyak algoritma klasifikasi yang lebih kompleks.



Sumber: https://www.saedsayad.com/logistic_regression.htm

Cara Kerja Logistic Regression:

- Logistic Regression membuat prediksi awal menggunakan persamaan linear.
- Kemudian hasil dari persamaan tersebut diterapkan ke fungsi sigmoid (fungsi logistic).
- Setelah mendapatkan Probabilitas dari fungsi sigmoid, selanjutnya atur threshold, misalkan:
 - Jika $p > 0.5$, maka outputnya 1,
 - Jika $p \leq 0.5$, maka outputnya 0.

Logistic Regression

Kelebihan dan Kekurangan

Kelebihan Logistic Regression:

- Mudah dipahami dan diterapkan.
- Cocok untuk klasifikasi dengan daya komputasinya lebih rendah dibandingkan algoritma yang lain (seperti neural networks).

Kekurangan atau Keterbatasan Logistic Regression:

- Cenderung tidak dapat menangani hubungan non-linear dengan baik
- Rentan terhadap outlier.
- Umumnya hanya berkinerja dengan baik jika data berdistribusi normal.
- Butuh penyesuaian jika data tidak seimbang (Imbalance)



Evaluasi Model Pada Tugas Klasifikasi

Model Evaluation

Evaluasi Model Klasifikasi

Evaluasi model dalam regresi sangat penting untuk memastikan bahwa model yang digunakan menghasilkan prediksi yang akurat dan dapat diandalkan. Ada beberapa metrik evaluasi yang umum digunakan untuk menilai kinerja model. Berikut adalah metrik-metrik evaluasi:

- Akurasi (Accuracy)
- Presisi (Precision)
- Recall (Sensitivitas atau True Positive Rate)
- F1-Score
- ROC Curve (AUC Score)

Model Evaluation

Confusion Matrix

Confusion Matrix adalah tabel yang digunakan untuk menggambarkan kinerja model klasifikasi. Matrix ini menunjukkan jumlah prediksi yang benar dan salah pada setiap kelas yang ada. Dari confusion matrix ini, kita bisa menghitung metrik-metrik seperti presisi, recall, dan F1-score.



		Predicted class		
		Classified positive	Classified negative	
Actual class	Actual positive	TP	FN	$\text{TPR: } \frac{TP}{TP + FN}$
	Actual negative	FP	TN	$\text{FPR: } \frac{TN}{TN + FP}$
		$\text{Precision: } \frac{TP}{TP + FP}$	$\text{Accuracy: } \frac{TP + TN}{TP + TN + FP + FN}$	

		PREDICTIVE VALUES	
		POSITIVE (CAT)	NEGATIVE (DOG)
ACTUAL VALUES	POSITIVE (CAT)	TRUE POSITIVE  3	FALSE NEGATIVE  1 TYPE II ERROR
	NEGATIVE (DOG)	FALSE POSITIVE  2 TYPE I ERROR	TRUE NEGATIVE  4

Confusion Matrix

Multiclass Classification

		Predicted		
		apple	mango	pear
Actual	apple	a	b	c
	mango	d	e	f
	pear	g	h	i



Positive = apple Negative = not apple		Predicted	
		Positive	Negative
Actual	Positive	TP = a	FN = b+c
	Negative	FP = d+g	TN = e+f+h+i

Positive = pear Negative = not pear		Predicted	
		Positive	Negative
Actual	Positive	TP = i	FN = g+h
	Negative	FP = c+f	TN = a+b+d+e

Positive = mango Negative = not mango		Predicted	
		Positive	Negative
Actual	Positive	TP = e	FN = d+f
	Negative	FP = b+h	TN = a+c+g+i

Model Evaluation

Accuracy

Akurasi mengukur seberapa sering model memberikan prediksi yang benar. Ini adalah metrik yang paling sederhana, tetapi bisa kurang informatif pada dataset yang tidak seimbang.

Skala skornya dari 0-1 atau 0 % - 100 %.

- **Rumus Akurasi:**

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

- **Contoh:** Jika dari 100 data, model benar memprediksi 90 data, maka akurasi adalah 90%.

Model Evaluation

Presisi (Precision)

Presisi mengukur seberapa banyak prediksi positif yang benar (True Positives) dibandingkan dengan total **prediksi positif** yang dilakukan oleh model (True Positives + False Positives). Skala skornya dari 0-1 atau 0 % - 100 %.

- **Formula:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Contoh: Presisi 50% atau 0.5** berarti bahwa dari semua prediksi positif yang dibuat oleh model, hanya setengah dari prediksi tersebut yang benar-benar positif (akurat)

Precision / Positive Predicted Value (PPV)

Case

- Case : Fingerprint identification in a building/company

	Employee	Not an Employee
Detected as Employee	 70 	 3 
Detected as Non Employee	 17 	 10 

Model Evaluation

Recall (Sensitivitas atau TPR)

Recall mengukur seberapa banyak prediksi positif yang benar dibandingkan dengan jumlah total data yang sebenarnya positif (True Positives + False Negatives). Skala skornya dari 0-1 atau 0 % - 100 %.

- Formula:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- Contoh: Recall 50% atau 0.5 berarti bahwa dari semua pasien yang sebenarnya menderita penyakit (positif), model hanya berhasil menemukan 50% dari mereka. Setengah dari pasien yang seharusnya diprediksi positif justru diprediksi negatif oleh model (False Negatives).

Recall / Sensitivity / True Positive Rate (TPR)

Case

- Case : Covid-19 test

	COVID-19 Positive		COVID-19 Negative	
Detected as COVID-19 Patient		1000 ✓		800 ✗
Detected as not a COVID-19 Patient		200 ⚠		8000 ✓

Model Evaluation

F1-Score

F1-Score adalah rata-rata harmonik dari presisi dan recall, memberikan gambaran tentang keseimbangan antara keduanya. F1-Score sangat berguna ketika kita memiliki dataset yang tidak seimbang (misalnya, jumlah kelas positif dan negatif sangat berbeda). Skala skornya dari 0-1 atau 0 % - 100 %.


- Formula:

$$\text{F1-Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Model Evaluation

ROC-AUC


Kurva ROC menunjukkan kinerja dari sebuah pengklasifikasi biner dengan berbagai ambang keputusan (decision threshold). Kurva ini memplot **True Positive Rate (TPR)** terhadap **False Positive Rate (FPR)**.



Skor AUC ROC adalah area di bawah kurva ROC. Skor AUC ROC berkisar antara 0 hingga 1, di mana 0.5 menunjukkan tebakan acak, dan 1 menunjukkan kinerja yang sempurna.

Model Evaluation

ROC-AUC



Model Evaluation

Classification Report

- Classification report adalah laporan yang menampilkan kinerja keseluruhan suatu model.
- Contoh hasil dari Classification Report :

	precision	recall	f1-score	support
0	0.82	0.88	0.85	421
1	0.75	0.65	0.69	231
accuracy			0.80	652
macro avg	0.78	0.76	0.77	652
weighted avg	0.79	0.80	0.79	652

precision: Rasio TP terhadap TP + FP.

recall: Rasio TP terhadap TP + FN.

f1-score: Rata-rata harmonik precision dan recall

support: Jumlah sampel aktual dari label tertentu.

macro avg: Nilai rata-rata untuk setiap metrik

weighted average: Nilai rata-rata suatu metrik dengan mempertimbangkan proporsi jumlah data di setiap kelas.



External References (Practice)

Colab Link

[Visit Here](#)



Hacktiv8id



Hacktiv8id



Hacktiv8



Hacktiv8 Indonesia