



Foundations of Embeddings & Vector Databases



Syarat dan Aturan dalam Pelatihan

Untuk mengikuti materi pelatihan berikut ada beberapa hal yang harus diperhatikan oleh peserta:

- Peserta diharapkan sudah memiliki pengetahuan dasar tentang Python dan Dasar Pengolahan Data.
- Peserta diharapkan memperhatikan materi dan mencatat materi atau penjelasan yang disampaikan dari instruktur.
- Instruktur diharapkan dapat menjelaskan materi dengan jelas dan memastikan peserta pelatihan dapat memahami topik yang dibahas.
- Materi yang diajarkan sebagian besar adalah praktik atau menggunakan Google Colab (Jupyter Notebook).



Daftar Isi

- From Keyword Search to Semantic Search
- Embeddings, Vector Database & RAG Flow
- Hands on: Visualisasi embedding similarity, Retrieval/Search Technique & Vector Database



Objectives

- Peserta dapat menjelaskan dan memahami apa itu Embedding, Vector Database dan macam-macam teknik pencarian.
- Peserta dapat memahami langkah-langkah untuk melakukan Embedding, Search/Retrieval, dan Pembuatan Vector Database.
- Peserta dapat memahami alur dasar dari RAG.



From Keyword Search to Semantic Search

Sistem Pencarian

Apa itu Sistem Pencarian?

Sistem pencarian adalah sistem yang digunakan untuk menemukan informasi yang relevan dari kumpulan data berdasarkan suatu query atau kata kunci yang dimasukkan oleh pengguna.

Dengan kata lain, sistem pencarian membantu pengguna mencari dan mengambil informasi yang paling sesuai dari data yang tersedia.

MACAM-MACAM APLIKASI SISTEM PENCARIAN



Search Techniques

Macam-Macam Teknik Pencarian

Pada sistem modern seperti RAG (Retrieval-Augmented Generation), sistem pencarian dapat menggunakan beberapa teknik seperti:

- Keyword Search
- Semantic Search
- Hybrid Search

Pada sesi ini kita akan fokus dengan Keyword Search dan Semantic Search.

Keyword Search vs. Semantic Search:

 KEYWORD		 SEMANTIC
Exact Keyword Matching	How it Works	Understands the meaning behind what you're asking
Focuses on single words or exact phrases	Query Handling	Looks at the full sentence and figures out what you really mean
May show pages with the word but not what you need	Relevance of Results	Shows results that match your intent, even without exact words
Good for simple, direct searches	User Experience	Better for natural, question-style searches (like how you talk)
Easy to tell why a page shows up. It has the words you typed	Transparency	Harder to see why something ranked. It uses deeper analysis
News, academic papers, short or exact searches	Best For	Voice search, shopping, helpful content, personalized answers

Search Techniques

Keyword Search

Keyword search adalah metode pencarian informasi yang bekerja dengan mencocokkan kata kunci (keyword) dari query pengguna dengan kata yang terdapat dalam dokumen atau data.

Artinya, sistem akan mencari dokumen berdasarkan kecocokan kata (exact match) dengan input kata yang diberikan oleh pengguna.



Cara Kerja Keyword Search

Search Techniques

Keyword Search

Kelebihan

- **Akurasi Tinggi untuk Pencarian Spesifik:** Sangat efektif jika Anda mencari kata kunci atau istilah teknis yang sudah pasti (*exact match*).
- **Kecepatan Pemrosesan:** Memberikan hasil yang sangat cepat karena proses pengindeksan dan pencariannya sederhana.
- **Transparansi dan Deterministik:** Logikanya mudah dipahami; hasil muncul karena ada kecocokan kata secara langsung, sehingga mudah untuk diaudit.
- **Hemat Sumber Daya:** Biaya komputasi dan infrastruktur yang dibutuhkan jauh lebih rendah dibandingkan dengan pencarian berbasis AI atau model bahasa besar.
- **Kontrol Pengguna:** Memberikan kontrol penuh kepada pengguna melalui operator pencarian (seperti tanda kutip atau operator Boolean).

Kekurangan

- **Minim Pemahaman Kontekstual:** Tidak mampu membedakan kata yang sama dengan makna berbeda (homonim). Misalnya, mencari "bisa" mungkin menampilkan hasil tentang racun ular atau kemampuan melakukan sesuatu secara acak.
- **Ketergantungan pada Ejaan (Typo):** Jika ada satu huruf yang salah, sistem sering kali gagal menemukan dokumen yang relevan.
- **Masalah Sinonim:** Tidak bisa mengenali bahwa dua kata berbeda bisa bermakna sama. Jika Anda mencari "ponsel", sistem mungkin melewatkan dokumen yang hanya menggunakan kata "handphone".
- **Pencarian Literal:** Hanya mencari kecocokan karakter secara fisik, sehingga tidak bisa menangkap maksud atau niat (*user intent*) di balik pencarian tersebut.


Search Techniques

Semantic Search

Semantic search adalah metode pencarian informasi yang memahami makna dan konteks dari sebuah query, bukan hanya mencocokkan kata yang sama seperti pada keyword search.

Dengan semantic search, sistem dapat menemukan dokumen yang memiliki arti yang relevan, meskipun kata yang digunakan berbeda.

Pada semantic search, teks akan diubah menjadi representasi numerik (embedding/vector) menggunakan model AI atau NLP.



Cara Kerja Semantic Search

Search Techniques

Keyword Search

Kelebihan

- **Memahami Konteks dan Makna (Intent):** Sistem dapat membedakan kata yang sama namun memiliki arti berbeda berdasarkan kalimatnya. Ia memahami *apa* yang Anda maksud, bukan hanya *apa* yang Anda ketik.
- **Menangani Sinonim dan Variasi Kata:** Anda tidak perlu mengetik kata yang persis sama dengan yang ada di dokumen. Jika Anda mencari "kendaraan roda dua", sistem bisa menampilkan hasil tentang "motor" atau "skuter" karena keduanya secara semantik berkaitan.
- **Toleransi terhadap Kesalahan Ketik (Typo):** Karena pencarian dilakukan berdasarkan representasi vektor (ruang matematis), sistem tetap bisa menemukan hasil yang relevan meskipun ada sedikit kesalahan ejaan atau penggunaan bahasa gaul.

Kekurangan

- **Konsumsi Sumber Daya Tinggi (High Compute):** Memerlukan GPU atau CPU yang kuat untuk proses *embedding* (mengubah teks menjadi vektor) dan perhitungan matematis (seperti *cosine similarity*).
- **Membutuhkan penyimpanan khusus berupa Vector Database** (seperti Pinecone, Weaviate, atau Qdrant)
- **Lemah pada Exact Match:** Terkadang gagal jika pengguna mencari istilah yang sangat spesifik seperti nomor seri, kode SKU, atau nama merek yang unik..
- **Masalah Latensi (Latency Issues):** Waktu respon cenderung lebih lambat dibandingkan *keyword search*.
- **Sensitif terhadap Kualitas Data dan Model.** Jika muncul hasil yang tidak relevan, sulit untuk menentukan bagian mana dari model *embedding* yang perlu diperbaiki.



Embeddings, Vector Database & RAG


Embedding

Apa itu Embedding?

Embedding adalah representasi data (seperti teks, gambar, atau audio) dalam bentuk vektor angka sehingga dapat dipahami dan diproses oleh model machine learning atau AI.

Dengan kata lain, embedding mengubah data yang awalnya berupa teks atau informasi tidak terstruktur menjadi angka dalam bentuk vektor.

Contoh model embedding yaitu BERT, Sentence Transformers, OpenAI Embedding, E5 Embedding, Gemini Embedding, dll.



Sumber: <https://web.engr.oregonstate.edu/>


Vector Database

Apa itu Vector Database?

Vector Database adalah database yang dirancang untuk **menyimpan** dan **mencari data dalam bentuk vektor (embedding)** sehingga memungkinkan pencarian berdasarkan kemiripan makna (**similarity**), bukan hanya kecocokan kata.

Vector database banyak digunakan pada sistem **semantic search**, **recommendation system**, dan **RAG (Retrieval-Augmented Generation)**.

Untuk mengukur **seberapa mirip dua vektor** (misalnya embedding query dan embedding dokumen), Anda dapat menggunakan metrics seperti **Cosine Similarity**, **Dot Product** atau **Euclidean Distance**.



Sumber:

<https://learn.microsoft.com/en-us/data-engineering/playbook/solutions/vector-database/>

Vector Database

Distance / Similarity Metrics

Metode	Konsep	Cara Mengukur	Interpretasi Nilai	Kelebihan	Kekurangan
Cosine Similarity	Mengukur sudut antara dua vektor	Membandingkan arah vektor	Nilai mendekati 1 = sangat mirip , 0 = tidak berhubungan	Tidak dipengaruhi panjang vektor, sangat cocok untuk semantic search	Tidak mempertimbangkan panjang vektor
Dot Product	Mengalikan elemen vektor lalu dijumlahkan	Mempertimbangkan arah dan panjang vektor	Nilai semakin besar = semakin mirip	Komputasi cepat, banyak digunakan pada vector database	Sensitif terhadap skala atau panjang vektor
Euclidean Distance	Mengukur jarak langsung antara dua vektor	Menghitung jarak geometris antar titik	Jarak kecil = lebih mirip , jarak besar = kurang mirip	Mudah dipahami secara matematis	Sensitif terhadap skala data dan panjang vektor

Vector Database

Top Vector Databases

Vector Database	Fitur Utama
ChromaDB	Open-source, mudah digunakan untuk pengembangan lokal, integrasi kuat dengan Python dan framework AI seperti LangChain dan LlamaIndex, mendukung penyimpanan embedding dan metadata.
Pinecone	Managed vector database berbasis cloud, sangat scalable, performa tinggi untuk similarity search, dan menyediakan API yang mudah digunakan.
Weaviate	Open-source vector database dengan dukungan hybrid search (vector + keyword), memiliki GraphQL API, mendukung metadata filtering dan berbagai modul AI.
Qdrant	Open-source dengan performa tinggi untuk vector search, berbasis cloud maupun self-hosted, mendukung payload/metadata filtering , memiliki REST dan gRPC API, serta optimal untuk semantic search.
Milvus	Open-source vector database yang dirancang untuk skala sangat besar , mendukung miliaran vector, berbagai algoritma indexing, dan performa tinggi untuk large-scale similarity search.

RAG

Apa itu RAG?


RAG (Retrieval-Augmented Generation) adalah teknik dalam AI yang menggabungkan **pencarian informasi (retrieval)** dengan **model generatif seperti LLM** untuk menghasilkan jawaban yang lebih akurat berdasarkan data tertentu.

Dengan RAG, model tidak hanya mengandalkan pengetahuan yang ada di dalam model, tetapi juga **mengambil informasi dari dokumen eksternal** sebelum menghasilkan jawaban.

Komponen	Penjelasan
Retrieval	Sistem mencari dokumen atau informasi yang relevan dari database (biasanya dari vector database).
Augmented	Dokumen yang ditemukan ditambahkan sebagai context ke dalam prompt agar model memiliki informasi tambahan.
Generation	Model AI (LLM) menggunakan query + context tersebut untuk menghasilkan jawaban.

RAG

RAG Flow



Retrieval and Generation

Assignment



Tugas 1

Pada tugas ini gunakanlah dataset film yang dapat diunduh dari [Kaggle \(The Movies Dataset\)](#).

Gunakan file ``movies_metadata.csv`` sebagai sumber data.

Dari data tersebut kerjakanlah beberapa perintah berikut:

1. Buatlah keyword Search menggunakan **BM25** dan **TF-IDF** untuk mencari film berkaitan dengan:
 - robot
 - love
 - adventure
2. Buatlah Semantic Search dengan Vector Database (**Pinecone** dan **ChromaDB**) untuk mencari film berkaitan dengan:
 - Adventure movie with characters named Judy and Peter
 - Movies with scenes in New York City
 - movie about poet Arthur Rimbaud and Paul Verlaine relationship"

Tugas 2

Buatlah aplikasi sederhana yang dapat melakukan pencarian brand mobil dan juga dapat memberikan informasi seputar spesifikasi dari setiap mobil. Misalkan dapat melakukan pencarian:

- Mobil yang cocok untuk keluarga
- Mobil Listrik
- Mobil Autopilot
- Mobil hemat bahan bakar
- Mobil murah dibawah 250 juta dan keluaran tahun 2023

Gunakanlah “data_mobil.csv” sebagai informasi untuk melakukan pencarian tersebut. Download datasetnya [di sini](#).

Lakukanlah pencarian menggunakan Keyword Search (**BM25** dan **TF-IDF**) dan Semantic Search dengan **model selain dari model yang ada pada materi ini**, misalkan Anda dapat menggunakan [Gemini Embedding](#). Selain itu cobalah untuk simpan hasil embedding dengan Vector Database **Pinecone** dan **ChromaDB**.

Batas Pengumpulan: Hari ini, pukul 23.59 WIB
Pengumpulan melalui: Google Classroom



Practice

**Hands on: Visualisasi embedding similarity,
Retrieval/Search Technique & Vector Database**

Visit Here